居丽叶的简历项目2：自动化PPT生成Agent

自我介绍

自我介绍简短一点，只提及使用到的技术和自己负责的模块即可，不用展开说

面试官您好，我叫居丽叶，本科毕业于东南大学，硕士就读于中国传媒大学计算机与网络空间安全学院，在校期间我曾多次获得过奖学金，我的研究方向是AIGC图片检测，有一篇以xxx为主题的论文在投cvpr。此外，我还有一段竞赛经历，是参加的学校组织的AIGC创新创业大赛，开发了一款自动化PPT生成Agent，可以参考用户上传的PPT模版、依据用户上传的PDF中的文字内容，从而生成高质量的PPT。

以上是我的自我介绍，需要我给您详细介绍一下这个Agent项目吗?

简历写法

自动化PPT生成Agent| 挑战杯AIGC创新创业大赛一等奖

项目背景

市面主流文档转PPT工具普遍存在内容冗余、视觉单调、结构生硬等问题，尤其无法自动复现原文中的图片和表格，难以满足真实办公和学术场景下对高质量演示文稿的需求。

解决方案

- 设计基于**参考驱动的编辑式生成框架**，将幻灯片生成过程建模为对参考PPT的批量增删改（function call API序列），支持文本、图片等多类型元素的自动编辑与自我修正，显著提升内容结构、视觉风格的适配性与系统鲁棒性。
- 基于ViT模型提取幻灯片页面的图像 embedding，通过**层次聚类算法**进行视觉版式自动分组，并结合大模型gpt-4o抽取每类页面的结构化内容模式(schema)，支撑高效风格迁移。
- 构建**HTML化的幻灯片解析与编辑环境**，将原始XML结构转为HTML，显著降低大模型gpt-4o对页面布局的理解与操作难度。
- 设计并落地**多维度自动评价体系**，融合内容丰富度、设计美观性与结构连贯性等指标，自动评价分数与人工评分一致性达0.7以上。

项目成果

系统在Zenodo10K等多领域公开数据集上测试，内容、设计、连贯性三项指标较模板法/规则法基线平均提升13%~29%，结构连贯性得分提升超25%，最终平均得分3.67/5。

项目描述

先介绍项目背景，再说一开始是怎么做的，但是遇到了什么困难、挑战，尝试了什么新的方法，结论是什么（数值型评估指标），一定要突出项目“迭代”的过程。

我最近参与了学校组织的AIGC主题比赛，主导了一个自动化PPT生成项目。其实在动手前，我也调研了市面上不少类似的AIGC产品，比如kimi、PI

评论（50）

开发了一款自动化PPT生成Agent

S sanen 2025年9月25日
面试官问生成一份 ppt 需要多久?

朱时韵 2025年9月27日
一分钟左右

自动化PPT生成Agent

XL 飞书用户3703XL 2025年12月19日
面试官问，这个 agent 搭建的框架是什么，是基于 langchain 搭建的么，还是 autogen?

S SaintGeorge 2025年12月19日
这个项目本身没用框架，别的项目用 langgraph 多，看你熟悉哪个了，熟悉哪个说哪个

飞书用户1250RE 2025年12月26日
@SaintGeorge 如果 agent 搭建的框架是说用了 langgraph，有详细的回答话术吗？要注意什么细节?

S SaintGeorge 2025年12月26日
你可以参考项目 3 股票那个项目，把比如生成大纲，ppt 解析等都作为一个节点，然后生成 ppt 时候弄成一个意图识别，每个意图就对应一个 API（增加图像，增加文本这些），再背一背 langgraph 相关的八股

飞书用户1250RE 2025年12月26日
@SaintGeorge 好的感谢

function call API序列

夏 3月4日 11:16
怎么理解 funciton-call api 序列呢，就是串行调用 api 吗，从解

（https://pi.deepvinci.tech/login?share_token=OAPY4GDFMGCCQ）等，但发现它们普遍存在内容冗余、视觉单调、结构生硬的问题，尤其是对原文的图片和表格支持很差，往往只是用一段文本描述替代，实际效果并不理想。

因此，我设计的**自动化PPT生成Agent**项目，核心目标就是解决这些痛点。刚开始着手这个项目的时候，我其实也尝试过传统的做法，就是直接用大模型把文档分段，再按照预设模板去填充生成幻灯片内容。最初的效果还算“合格”，但是很快发现了一些根本性的短板。比如有的页内容堆叠得过于密集，视觉上非常单一，每一页都长得差不多；而且很多重要的原文图片、表格内容没法智能地映射到PPT里，只能变成一句文本描述。整个生成PPT流程看起来非常“机械”，没有那种高质量PPT应有的吸引力和条理感。

在项目推进过程中，我也不断反思，用户真实做PPT的时候，其实不会从零搭建每一页，大部分都是找一份类似的参考PPT，然后在模板基础上去改内容、换图片、调整结构。受到这个启发，我尝试让大模型“模仿人”的方式来生成PPT——不是每一页都从头生成，而是优先选取一页结构和风格相近的参考幻灯片，然后用一系列“编辑动作”去一步步修改成目标内容。这样不但保留了模板的美观性，还能灵活地把原文中的图片和表格插入到合适的位置，极大提高了可读性和信息量。

这样做就是让大模型具备了function call能力，能够理解结构化页面，再自动生成和调用一系列API式的编辑命令（比如replace_span、del_image、clone_paragraph、add_image、replace_table等），让大模型从“内容生成者”进化成“内容操作Agent”，实现真正意义上的自动编辑和内容迁移。

当然在落地过程中也遇到了不少挑战。比如怎么让模型理解每一页幻灯片的功能类型？哪些属于结构页（比如开场、目录、结尾），哪些才是真正的信息页？为此我用大模型做了聚类和结构化标签归类，让系统自动判断每一页的角色。再比如，原始PPT的文件格式通常是很难直接解析的XML，于是我引入了HTML渲染，把页面结构转成更适合模型理解的形式。整个生成过程还允许模型每一步都能检测生成效果，如果有错误还能自动调整编辑操作，保证最终输出的每一页都是合格的。

在实验和评测阶段，我不仅用传统的文本相似度等指标去评估，还设计了多维度的自动化评价体系，覆盖了内容丰富性、视觉设计和结构连贯性。最终结果非常理想，不仅在内容和设计两个维度上分别有了平均13%和29%的提升，整体的结构连贯性也大幅提高，最后的自动打分平均分达到3.67分（满分5分），显著超过了市场上主流产品的水平。

这个项目最让我有成就感的是，通过不断迭代优化，我让大模型在做PPT这件事上真正学会了“像人一样思考和操作”。也希望这个方案未来能为更多实际办公和教育场景带来便利和效率提升。

项目相关的问题

从输入到输出的整体流程？

析到生成

朱时韵 3月4日 11:25

是的，主要 api 实现在 pptagent/apis.py,API 使用规范在 pptagent/roles/agent.yaml

unction call API序列

王霄宇 2025年8月18日

为什么要建模成 function-call API 序列?

SaintGeorge 2025年8月19日

主要为了基于现有模板进行内容替换和样式调整，而不是从零开始生成每一页。这样做一是能够最大限度地保留模板的视觉风格和排版结构，确保生成结果与参考模板风格一致；二是通过 API 式的更简单的编辑操作（如替换文本、插入图片、删除冗余元素等），实现了对多模态内容（如图片、表格）的精准控制和灵活插入，而让大模型一次性生成 ppt 难以控制结果，因为要后者难度更高，很容易造成内容冗余，格式混乱等问题；三是这种结构化的编辑方式增强了系统的可控性和可调试性，大大提升了生成过程的鲁棒性和最终输出的质量，后续想进一步增强效果，可以基于每一步的 function call 流程构建训练数据。

展开

支持文本、图片等多类型元素的自动编辑…

夏相 1月12日 20:53

被问到这里能创造出新的元素么

SaintGeorge 1月12日 21:10

可以新建图片，文本框，表格等常见的元素。太复杂的元素暂时不支持。

夏相 1月12日 21:30

这里的自动编辑和自我修正指的是什么

SaintGeorge 1月12日 21:35

自动编辑就是在 ppt 模板上增加，减少图片文本框等操作。修正指的是这个项目采用调用 API 方式生成 ppt（比如增加图片，增加文本框都封装成了 API），如果一个操作执行失败，会把错误信息反馈给大模型，让他重新生成调用 API 的命令。

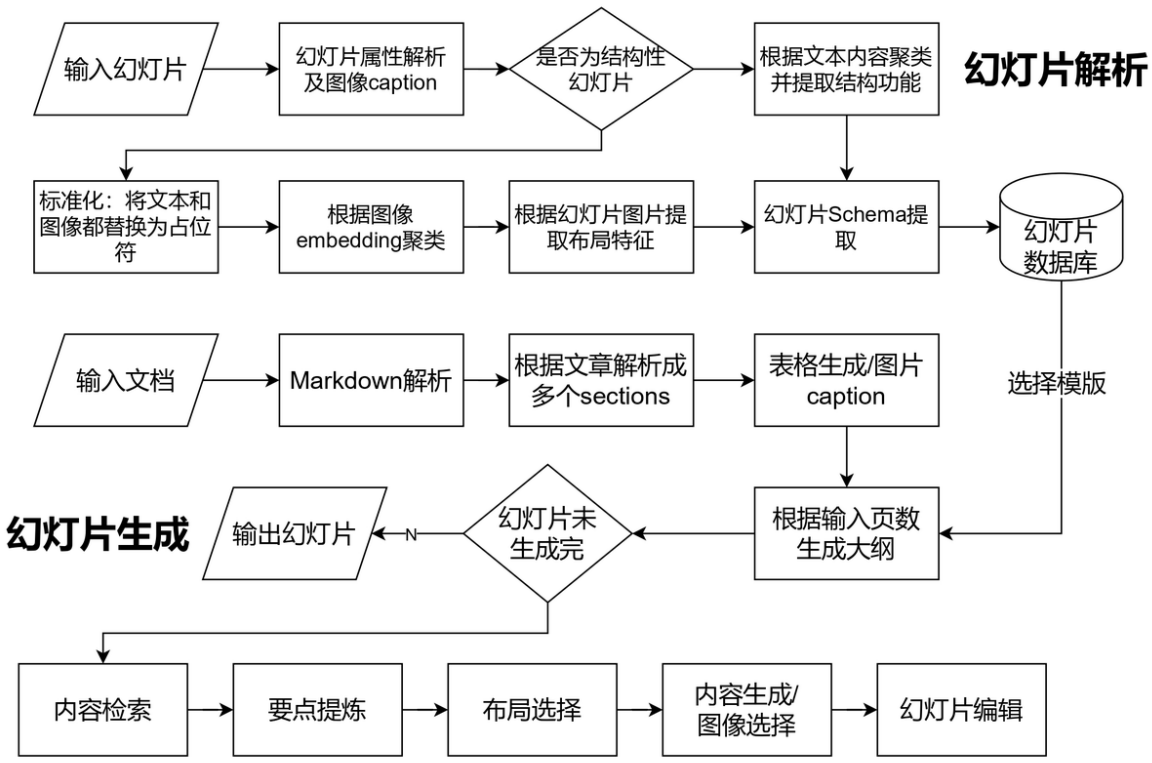

1. **输入准备**
   首先，用户需要上传两份文件：一份是PDF文档，作为PPT生成的内容来源；另一份是PPT模板，用于指定最终生成的PPT风格和结构。
2. **PPT模板解析**
   系统会先解析用户上传的PPT模板，逐页提取文本、图片等元素，并将每一页转换为图片，以便后续做版式聚类和视觉分析。
   同时会用视觉模型为PPT中的图片自动生成描述（caption），并根据页面的文本内容，自动识别哪些幻灯片是**结构性页面**（比如目录、章节标题、结尾等），哪些是**普通内容页**。
   对结构性页面会提取每类幻灯片的结构功能和布局schema，为后续内容生成提供参考。
3. **PPT模板聚类与内容模式抽取**
   在解析PPT模板的基础上，系统会自动聚类内容型幻灯片的版式，抽取每类页面的内容分布和布局模式，形成完整的schema库。这样可以保证后续生成的新PPT能够严格复用模板的风格、配色和排版方式。
4. **PDF内容解析与结构化**
   用户上传的PDF文件会被转成Markdown格式，然后通过大模型梳理标题结构，按章节切分成多个语义块（chunk）。每个语义块会进一步用语言模型和视觉模型抽取结构化信息，包括正文、表格、图片，以及每个多模态元素的上下文、摘要和说明，最终整理为带层级的结构化文档对象。
5. **内容与模板对齐生成PPT**
   系统会根据结构化的文档内容和模板schema，智能地将每个内容块匹配到最合适的幻灯片版式。首先生成大纲，然后根据大纲生成API编辑命令，通过API编辑命令自动填充文本、图片、表格等内容。生成过程中不仅关注内容的准确性，还会兼顾PPT的整体结构、视觉设计和内容连贯性。
6. **输出与保存**
   最终系统会生成一份风格与模板一致、内容结构合理、设计美观、连贯性强的PPT文件，并提供给用户下载。

PPT中的图片元素（比如一页里有插画、表格截图、logo）是怎么从每一页整页图片（即PPT页面截图）中被单独提取出来的？

基于ViT模型提取幻灯片页面的图像 emb…

sanen 2025年9月22日

面试官说据他了解，单纯用 vit 做 embedding 进行聚类的效果并不好，这要怎么回答啊

朱时韵 2025年9月23日

@sanen 是的，我在做聚类时，也发现语义和内容会干扰结果：比如一页有算法公式、一页有风景图，它们可能被拉开很远，虽然布局其实很接近。所以我在项目里做了两个改进：

第一，把文字替换为占位符、图片替换为纯色块，只保留布局信息；

第二，用层次聚类代替 K-means，通过阈值来控制聚类效果。最后再结合大模型抽取的 schema 做校正，这样最终聚类的结果在版式风格上会更稳定。

基于ViT模型提取幻灯片页面的图像 emb…

夏相 1月12日 20:49

这个为什么要进行自动分组

SaintGeorge 1月12日 20:52

后续生成 ppt 的时候要为每个 ppt 选择一个模板，这里聚类就是为了得到一些模板（比如元素多的模板，元素少的模板，图多的模板等），这样后续生成 ppt 的时候就在模板的基础上进行增减。

ViT模型

王霄宇 2025年8月18日

为何选 ViT 模型提取页面 embedding

SaintGeorge 2025年8月19日

ViT 是现在主流多模态大模型的架构基础，具有以下优点：

1. 全局信息捕捉能力：ViT 将图像分割为多个图像块，通过自注意力机制处理这些块，能够捕捉图像中的全局依赖关系，有助于理解页面的整体结构和元素间的关联。

2. 与 NLP 模型的统一性：ViT 基于 Transformer 架构，与 NLP 中的模型具有相似的结构，便于统一处理文本和图像数据，实现多模态融合。

3. 可扩展性：ViT 在很多数据集

提取PPT中的图片时，并不是对每一页页面截图做分割或识别，而是用python-pptx**直接遍历PPT结构化对象（如每页的Picture类型shape）获取图片元素**。这样可以精准、高效地获取每张图片的文件、尺寸、出现次数、页码分布等详细信息，完全避免了视觉分割或OCR等冗余操作，也不会漏掉或误判任何图片。

PDF和PPT解析是怎么做的

PDF文件：

- 接下来解析用户上传的PDF文件，将其转化为markdown格式，从中提取的图片和元数据转存为jpg、json格式。
- 针对markdown文本，根据标题结构（以 `#` 开头的标题）提取出标题结构，然后利用llm帮助优化标题结构（比如纠正错误嵌套）。然后根据标题进行chunking，合并过于小的块。
- 接下来异步的解析每一个块：解析块中的元数据和文本、表格、图像等内容。对于图像和表格，收集其最近的上下文段落和子章节，然后将表格、图片关联到最相关的子章节。然后调用LLM生成当前块的摘要。

PPT文件：

- **数据预处理**：首先提取PPT中所有的图像，并调用LLM生成图片描述
- **识别幻灯片的布局模板**：首先调用LLM对功能型PPT和内容型PPT进行分类，功能型PPT（包括开头，目录，章节大纲和结尾）往往具有显著特征（例如感谢收看，章节1等）；对于内容型PPT，按布局聚类分组，先用图片embedding之间的余弦相似度做层次聚类，再用视觉模型分析每一类PPT其布局风格。
- **从幻灯片中提取内容**：分析每一类幻灯片的内容模式和结构schema，包括元素类型、元素描述等。

怎么对内容型页面做聚类和归纳？

筛选内容型页面

首先通过文本内容或模型判断哪些页面是结构性页面（如含有“目录”、“Contents”、“Conclusion”等关键字的幻灯片），除此以外的幻灯片都是内容型页面

图片嵌入提取与相似度分析

对这些页面生成页面截图，然后用vision Transformer的base版本（google/vit-base-patch16-224-in21k）提取图片embedding向量。

同时为了保障聚类时不受文本和图像内容的影响，从而只关心布局，将幻灯片中所有的文字都替换为占位符“a”，将所有图片都替换为纯色块。

聚类分析

计算所有内容性页面之间的embedding相似度，用层次聚类算法将版式/风格相近的页面聚为一类。例如，介绍背景这种图片比较丰富会被聚为一组，讲解算法伪代码这种格式比较单调的页为另一组。

归纳模板和特征

对每个聚类结果，归纳其主要的版式特征和内容功能，比如标题位置、配色、包含的元素类型等，选出一个代表性页面作为“模板”，并提取该类页面的内容schema。

形成内容性页面库

上表现优异，能够处理高分辨率图像和复杂页面布局，适用于各种网页和文档的分析任务。

4. 高效特征提取：ViT 通过线性映射将图像块转换为嵌入向量，结合 Transformer 的编码器，能够高效地提取页面的特征表示

展开

ViT模型

rhy 2025年10月30日

面试官问为什么不用 CLIP 模型，CLIP 模型对资源的消耗明显更少

SaintGeorge 2025年10月30日

clip 的优势在于图像-文本对齐，而这里要做的是图像embedding，然后计算图像之间的相似度，没有文本信息，所以用 ViT。另外这里用的 ViT 模型（google/vit-base-patch16-224-in21k）参数量也很低只有 300 多 M，

gpt-4o抽取每类页面的结构化内容模式(s…

王霄宇 2025年8月17日

gpto 如何抽取 schema

SaintGeorge 2025年8月17日

这里是再 prompt 里定义的，传个 GPT4o 的是 html 格式的 ppt，再 prompt 里定义：

解析 HTML 中所有 <p> 段落和 <img> 图像元素，把每个 <p> 的文本内容原样保存（保留换行符），每个 <img> 用 alt 属性作为图像描述，然后根据它们的样式和位置判断它们在幻灯片中的角色，比如主标题、副标题、段落要点或主图、头像等。生成的 JSON 以“角色名称”为键，对应值中包含“用途说明”（不透露具体内容）、类型（文本或图像）、以及文本段落或图片 alt 数据列表。总之，就是把 HTML 元素 “按段落分”、按角色定位，然后映射到 JSON Schema 中。

展开

支撑高效风格迁移

sanen 2025年9月25日

这个支持高效风格迁移是什么意思啊

最终将每类内容性页面及其模板、主要特征、功能说明等做结构化存储，供后续生成新PPT时复用。

聚类原理

我用的是自底向上的贪心层次聚类方法。构建了一个余弦相似度矩阵S，衡量两张幻灯片之间的相似性，一开始每张幻灯片是一个簇。然后每次贪心地选相似度最高的一对未合并的幻灯片进行合并，也就是将两个簇合并，合并之后对应的行列设为 0。通过设定阈值θ控制合并停止，而不是事先预设簇数。这个说法的优点是实现简洁、阈值控制灵活。

聚类的时候不准确怎么办?

1. **检查相似度矩阵的构建方式**
   - 我会尝试不同的embedding模型，以及对embedding模型进行微调，保障风格形式接近的幻灯片在特征空间内接近。还可以尝试别的距离计算方式，比如欧氏距离或者马尔科夫距离等。
2. **调整阈值 θ**
   - 阈值过高会导致聚类成的簇数量过多，阈值过低会导致明明不相似的幻灯片也聚成一类，可以测试不同的阈值，选择最优阈值。
3. **人工校正**
   - 对于存在明显异常的簇，可以进行手动修正。
4. **采用更健壮的聚类算法**
   - 目前的算法属于贪心式的层次聚类，它对异常值敏感。可以尝试 K-means、DBSCAN 等其他聚类算法，看哪种效果更好。

每个类中的代表性页面是怎么选出的?

我们会在每个类别的聚类结果中，选取包含元素最多的页面作为代表性页面，即统计每页的“元素（shapes）数量”，选择shape数量最多的那一页作为模板页面。因为它通常包含了该类版式的全部核心元素，有助于结构抽取和模板复用。

提取出的结构schema包括哪些内容?

元素类型与位置

- 比如包含哪些shape（标题、正文文本框、图片、图标、表格等），每个shape的类型和空间分布。

元素功能说明

- 每个元素在页面中的角色（比如“主标题”、“副标题”、“内容文本”、“图片区”、“页脚说明”等）。

样式与版式特征

- 包括配色、字体、对齐方式、占页面的比例、是否有装饰元素等视觉特征（可选）。

内容示例或占位说明

- 每个结构元素预期填充什么类型的内容（如“章节名称”、“Logo图片”、“日期”等）。

朱时韵 2025年9月27日

“支持高效风格迁移”就是说，系统能先学会你上传的 PPT 模板长什么样（比如标题页怎么排版、内容页是左图右文还是上文下表），然后在生成新 PPT 时，把 PDF 里的文字、图表、图片自动套进这些版式里，让最后出来的 PPT 既保留模板的美观统一风格，又能准确承载新内容，而不是像单纯复制粘贴那样杂乱无章。

HTML化的幻灯片解析与编辑环境

王霄宇 2025年7月30日

这段是怎么理解?

SaintGeorge 2025年7月30日

具体来说就是把幻灯片中存储的 XML 元素映射到对应的 HTML 结构，降低 GPT-4o 理解页面结构和调整布局的难度。

XML 表示冗长、嵌套深，幻灯片文件（如 PowerPoint 的 pptx）底层是大量标签化的 XML 结构，包含布局、样式、元素位置等信息，格式复杂且对大模型不友好。

HTML 更贴近 Web 渲染与编辑，HTML 具有直观的标签体系、样式（CSS）和 DOM 树，浏览器提供成熟的解析与操作 API，使得可视化编辑更简单。

展开

刘志豪 2025年9月2日

那这个 XML 转 HTML 的操作是在 PPT 解析之前还是说解析后的布局模式和结构化存储转为 HTML 格式

SaintGeorge 2025年9月2日

解析后的 PPT，在生成 PPT 时转成 HTML 格式。

将原始XML结构转为HTML

sp 3月22日 15:18

如何把 XML 结构转为 HTML?

SaintGeorge 3月22日 16:01

解析后的 PPT，将所有元素添加 <p><li>等格式，在生成 PPT 时转成 HTML 格式。

与页面逻辑相关的元信息

- 例如属于“开场页”、“章节页”、“结尾页”，在PPT整体结构中的作用。

它能完整描述代表性页面的排版逻辑，为后续内容自动填充和风格迁移提供标准化的“蓝图”。

PDF是如何按章节切分chunk的?

（正则提取标题→大模型优化→编辑距离对齐→按标题切分→合并短块）

PDF转Markdown后，切分chunk的关键是**以标题为锚点，结合大模型优化结构，再通过编辑距离对齐原始内容**。具体分为以下步骤：

1. 先将PDF转为Markdown，正则抽取所有标题行（如`^#+\s+.*`），区分章节层级，处理重复和层级混乱。(例如，原始标题可能包含重复项（如多个`## 相关工作`）或层级混乱（如“第2节”后直接接“第5节”）。)
2. 将原始标题传入大语言模型（如GPT-4），通过Prompt指令（如“整理重复标题、补全层级关系”）生成清洗后的标题列表大模型输出结构化JSON，包含每个标题的层级（level）和内容（title）.
3. 由于清洗后的标题可能与原始标题存在字符差异（如修正错别字），需通过**编辑距离（Levenshtein距离）**计算相似度，保证切分点严格落在原文对应位置。
4. 遍历文本，遇到对齐后的标题新建chunk，将内容划分到各自章节。
5. 对小于阈值（如64字）的chunk，按父章节或前后语义自动合并，避免碎片化。

这种切分chunk的方式如何保证语义完整性?

语义完整性的保障主要有三点：

1. **鲁棒的标题对齐**：通过编辑距离匹配+阈值过滤（如相似度>70%），避免误匹配不相关标题； 保留原始标题与清洗标题的映射关系，确保分割点严格基于原文位置。
2. **上下文感知的块合并：**合并过短块时，优先检查前后文语义关联（如“方法”章节中的子小节短句，合并到父级更合理）；
3. **多模态内容归属**：在切分阶段识别图片、表格的上下文段落（如“如图1所示”前后的文字），会将其强制关联到最近的标题块，避免遗漏；后续解析阶段使用视觉模型（如BLIP）为图片生成描述，LLM为表格补充标题，增强内容关联性。
4. **大模型二次验证**：切分完成后，用LLM对每个chunk生成摘要，检查是否包含完整语义单元（如“方法”chunk应包含算法描述，而非跨章节的结果数据）；对疑似跨章节的块，如果下页开头并非新章标题，则应与前页末尾合并为同一Chunk，然后通过Prompt指令（如“判断该内容是否属于当前章节”）触发人工或自动修正。

以上的做法虽然已经对语言完整度做了优化，但也难以100%保证语义完整，主要原因如下：

切分依赖标题锚点，若原文存在以下情况，可能导致语义断裂：

1. **本质是“以标题为锚点”的分块**，没有深度分析正文内容，所以：
   - 某些内容如果作者本身就写在了标题外（比如摘要写在引言之前），会被归到前一个块或第一个块里。
   - 标题太密、太散、标题级别混乱，都可能让语义被切断或丢失上下文。

融合内容丰富度、设计美观性与结构连贯…

飞书用户6802ZM 1月13日 14:44

详细介绍这边的评价指标。然后面试官说 ppt 整体的美观度怎么评估？能不能自己设置一个关于生成 ppt 美观的评价【】【可能留白很多，可能元素不够多这类的】

S SaintGeorge 1月13日 14:46

可以，这就是写 prompt 让大模型打分，规则是你自己定的。

内容丰富度、设计美观性与结构连贯性

S sanen 2025年10月21日

这个评价是输入生成的 ppt 文件吗？还是 html 格式的呢？

S SaintGeorge 2025年10月21日

ppt 文件

人工评分一致性

飞书用户6802ZM 1月13日 14:43

面试官问人工测评具体是干嘛

S SaintGeorge 1月13日 14:45

就是我先写了 prompt 让大模型去给 ppt 打分，然后又用同样的规则让人类给生成的 ppt 打分，如果两者打分结果比较一致，那就说明大模型打分是合理的，我们就相信大模型打分的结果。

按照预设模板去填充生成幻灯片内容

用户674744 2025年11月17日

这个过程是人工去填充么

朱时韵 2025年11月17日

不是，自动填充，规则匹配 + 内容映射

用户674744 2025年11月17日

这是如何匹配和映射的

朱时韵 2025年11月17日

1. 先给模板打标签：预设的 PPT 模板会提前定义好固定区域和对应规则，比如 “标题区（只填核心主题，≤15 字）” “要点区（最多 3 条，每条≤25 字）” “图片区（匹配与内容相关的图）” “表格区（接收结构化数据）”；
2. 大模型拆分文档并分类：把输入文档拆成 “标题、核心观点、案例、数据结论” 等模块，同时

2. **块的“最小长度合并”虽然能减少碎片，但也可能把本应独立的小节合并成了大节，**比如很短的“致谢”会被合到“结论”里。
3. **多模态内容**：图片、表格未被正确关联到对应段落。

这种基于标题锚点的切分效率高，适合处理长文档，大模型优化结构后可直接用于PPT大纲生成； 通过编辑距离对齐+最小块合并，在90%+场景下保证章节级语义完整，极端情况（如无标题文档）可结合滑动窗口+LLM语义聚类作为补充。

后续优化：

- **无标题文档**：使用LLM提取段落关键词，聚类生成虚拟标题后再切分；
- **多语言文档**：结合语种检测与对应语言模型（如Chinese-LLaMA）优化标题结构；
- **实时反馈机制**：在PPT生成阶段，允许用户手动调整chunk边界，反向优化切分逻辑。

为啥不用embedding?

用的是编辑距离（字符相似度），因为很多PDF转出来的文本“上下文很短、很稀疏”，用embedding反而不一定稳。

工程上“编辑距离”其实很鲁棒，且快，对于小块文本足够用了。

为什么要生成大纲?

1. 我们调用LLM根据结构性文档生成指定页数的大纲，能保证最后的PPT的页数满足用户需求，因为后续一张PPT就对应一页大纲，如果大纲页数不匹配则会将报错信息返回给LLM，重新生成大纲。
2. 可以根据生成的大纲，校验这页PPT对应正确的章节和子章节，以及图像和文字是否匹配，如果发现不匹配就会进行自动修正大纲，修改大纲的速度比修改PPT更低，因为修改PPT涉及很多API编辑命令。
3. 基于大纲预先总结的内容可以更好的生成PPT，尤其是章节过度页应该插在什么位置，如果不生成大纲直接生成PPT，经常会出现忽略章节过渡页、过渡页插错位置、过渡页序号不对的情况。

最后模型生成的PPT页数是多少页

因为结构型PPT可以根据需求灵活插入，所以我们要求最后生成PPT中，内容型PPT的页数就等于用户设置的页数。

怎么通过API编辑命令自动填充文本、图片、表格等内容?

在PPTAgent系统中，自动填充文本、图片、表格等内容的核心思路，是**把LLM输出的内容和页面结构schema结合，通过API式编辑命令，对参考PPT模板进行逐步“编辑”，**

识别出里面的图片、表格（比如标注 “这是产品销量表” “这是实验对比图”）；

3. 自动对号入座填充：程序按规则把拆分后的内容映射到模板对应区域 —— 比如把 “核心观点” 模块拆成 3 条短要点，自动填进模板的 “要点区”；把文档里的 “标题模块” 自动填进模板的 “标题区”；

4. 简单格式自动适配：比如要点区会自动加项目符号，标题区自动放大字体，表格区会把文档里的文字表格自动转成 PPT 表格格式（但早期传统方法里，图片常没法直接插入，只能填 “含产品销量图” 这类文本描述）。

展开

ND 飞书用户5060ND 1月27日 17:14 （…

这个过程不也是大模型修改内容适应模板的过程嘛，后面的改进是主要在大模型归纳了一页内容之后可以选择更合适的 PPT 模板再进行填充嘛？区别是前者不是先选择某个 PPT 的结构进行填充而是根据标签进行填充的是嘛

S SaintGeorge 1月27日 17:35

对，后面的改进是先写个大纲，列出来每一页的要填的东西，再根据大纲选 ppt 模板。

而是优先选取一页结构和风格相近的参考…

用户095466 2025年12月10日

这意思是每一类 ppt 生成时，是根据聚类时选出来的那个模板页进行增删改来修改的，不是根据对每一页不同的 ppt 进行生成的。

S SaintGeorge 2025年12月10日

每个 ppt 都是一页一页生成的，其中的每一页都要找到一个最相近的模板，基于模板进行增删改查

再自动生成和调用一系列API式的编辑命…

张克霄 1月28日 15:06

这个我有点没能理解，这些编辑命令是本来就有的，这里是生成调用这些？还是说是没有的，这里为了这个项目描述的？

S SaintGeorge 1月28日 15:14

本来就有这些命令，模型去调用他们来生成 ppt

实现内容的自动生成与替换。具体流程如下：

1. **API抽象**
   - 我们把PPT页面的各种编辑操作抽象为一组API命令，比如：
     - `replace_span`：替换某个文本区域
     - `del_image`：删除某个图片元素
     - `clone_paragraph`：复制某个段落或页面元素
     - `add_image`：添加图片到指定位置
     - `replace_table`：替换或插入表格内容
   - 这样，LLM只需根据大纲和内容，决定用哪些API命令、以什么参数调用即可。
2. **编辑流程**
   - 生成流程以参考模板为“蓝本”，LLM根据解析出的schema和要填充的内容，**逐步调用API命令**，在页面上定位并修改对应的文本框、图片、表格等元素。
   - 比如，大纲要求某页有章节标题和图片，LLM会先调用 `replace_span` 修改标题，再调用 `add_image` 插入图片。
3. **实现细节**
   - 每一次API命令都会被系统实际执行，并同步页面结构。
   - 编辑过程是“多轮迭代式”的，LLM会根据页面当前状态判断是否还需要进一步编辑，比如删除多余元素、合并内容块、或者纠正排版错误。
4. **优点**
   - 这种“API驱动的编辑”方式比传统直接生成PPT内容更灵活、可控、易于调试，也更像人类手工编辑PPT的流程。

大模型是如何决定现在要用哪个API工具的？

我们把所有的PPT编辑操作抽象成了一系列API命令，比如添加、删除、替换文本或图片。
大模型根据**输入的大纲、内容变更指令以及页面的当前结构**，自动判断应该调用哪个API。主要决策逻辑如下：

1. **分析内容变更类型与数量**
   - 对每条变更指令，模型会判断需要进行的是“内容修改”还是“元素数量调整”。
   - 例如，如果要更新段落的文本内容且数量不变，就选择 `replace_paragraph`
   - 如果需要增加新的段落，则用 `clone_paragraph`；需要减少段落，则用 `del_paragraph`。
2. **元素类型识别**
   - 如果变更涉及图片，模型会选用 `replace_image` 或 `del_image` 等专门用于图片编辑的API；
   - 表格则用 `replace_table` 等表格相关的API。
3. **根据页面结构和父子关系定位**
   - 模型会先理解页面HTML/结构化布局，准确定位要操作的元素（比如根据父级 `div`、当前 `p` 或 `img` 的 `id`）。
4. **根据具体规则和参数组合API**

视觉模型为PPT中的图片自动生成描述

飞书用户6802ZM 1月13日 14:46
有没有试过其他的 model，想对于 gpt 4.1 之类的有什么区别，为什么就选你简历写的那个？

SaintGeorge 1月13日 14:49
这种问题通用回复是
1. gpt4.1 刚出，在很多 benchmark 上比较领先。
2. 人工对比了你简历上这个项目时间段同时代的一些模型，发现 gpt4.1 效果最好。
3. 如果调用的小模型，还可以说成本，速度考虑等。这里用的 gpt4.1 不涉及这个。

结构性页面

sanen 2025年8月19日
结构性页面也需要做聚类吗？

SaintGeorge 2025年8月21日
不用，结构性页面本身已经格式很清楚了，主要就标题页，开始，结尾，目录几种，不用聚类

喻梦婷 2025年12月28日
那上面那个流程图里“根据文本内容聚类并提取结构功能”是不是写错了呀？

SaintGeorge 2025年12月28日
em，我说的有点问题，结构化页面就是聚类成这 4 类，这四类是定死的，内容型页面进行独立的聚类

系统会自动聚类内容型幻灯片的版式，抽…

用户095466 2025年12月29日
此时的 ppt 已经是图片了吗，是基于图片进行的页面结构和内容的提取吗

SaintGeorge 2025年12月29日
对，讲 ppt 转成图片，更方便做结构和内容提取

用户095466 2025年12月30日
你上面回答的不是说：这里是再 prompt 里定义的，传个 GPT4o 的是 html 格式的 ppt。意思是分析的不是图片而是 html 格式的 ppt 吗

SaintGeorge 2025年12月30日

- 如果需要增加元素，则优先用 `clone_paragraph` ，并且根据父级元素的已有最大id生成新id；
- 如果需要减少，则用 `del_paragraph` 或 `del_image` 等；
- 变更内容时，则用 `replace_paragraph` 、 `replace_image` 等。

5. **按步骤拆分复杂变更**
   - 如果一个命令需要同时调整数量和内容，模型会先用克隆/删除API完成数量变化，再用替换API修改内容。

大模型如何拿到内容变更指令？

1. **变更指令的来源**
   - 内容变更指令通常是由上游的**内容理解和规划模块**生成的。
   - 具体来说，系统会先对用户上传的PDF内容进行结构化解析，结合用户需求或大纲，自动拆解出每一页/每个区域需要填充、修改、删除或新增的内容。
   - 这些需求最终会被格式化为统一的“内容变更指令”列表，每条指令明确标注要操作的元素类别、类型、数量变更、原始内容和目标内容。
2. **指令的格式**
   - 每条内容变更指令都采用标准格式，如：

代码块

```
(element_class, type, quantity_change: int, old_data, new_data)
```

     - 例如：("title", "text", quantity_change: 0, [旧标题], [新标题])
3. **指令与页面结构的对齐**
   - 在正式下发指令前，系统会将变更需求与当前页面结构（如HTML、XML、或结构化PPT对象）做一次自动对齐，确保每个指令都能准确定位到需要操作的元素（比如具体的段落id或图片id）。
4. **模型的输入**
   - 最终，大模型会一次性接收**当前页面结构和内容变更指令**两部分输入，基于这些输入来推理需要调用哪些API，以及每个API的参数和目标对象。

最终生成效果是怎么评估的？

- **成功率**：通过计算所有幻灯片均成功生成的演示文稿百分比，衡量生成任务的鲁棒性。对于 PPTAGENT，成功的标准是在自我纠错后生成所有幻灯片且没有执行错误。对于 KCTV，成功则取决于生成的 LaTeX 文件能否成功编译。由于 DocPres 采用确定性的基于规则的转换方式，因此其不包含在此项评估中。
- **Rouge-L**： 通过计算生成文本与参考文本之间的最长公共子序列（LCS）来评估文本相似性。我们报告 F1 分数，以平衡精确率与召回率。
- **LLM-as-Judge** 使用 GPT-4o 作为评判模型，从“内容”、“设计”和“连贯性”三方面评价演示文稿质量。内容和设计评分按幻灯片平均计算，而连贯性则在整个演示文稿层面进行评估。

我看了下代码，布局模式提取传递的是图片，内容抽取传给 gpt4o 的是 html 格式的 ppt

结构化的文档内容和模板schema

李振柯 1月3日 12:20
结构化文档与模板 schema 都是什么格式的

SaintGeorge 1月3日 13:05
结构化文档是用户上传的 pdf，模板 schema 是之前第三步对用户上传的 ppt 进行抽取内容和布局模式，抽出来一些模板 ppt 页。

李振柯 1月3日 16:17 （编辑过）
我看第四步说对 PPT 内容解析并结构化，最终整理为一个带层级的结构化文档对象，这个对象是什么格式的呀？还有后续对齐的细节能简单解释一下嘛，谢谢

SaintGeorge 1月3日 16:30 （编辑…
第四步是对 pdf 做的，第 二三是对 ppt 做的，每个元素，比如 section，table 这些都是一个类，最终的结构化文档是 jsonl 格式的。比如如图

SaintGeorge 1月3日 16:35
对齐，就是基于用户上传的 pdf 中的文字、图片表格等，将这些东西首先规划成几页 ppt 的大纲，每一页 ppt 的模版基于用户上传的 ppt 选择最合适的，然后在模版的基础上将大纲里的内容填到 ppt 中

智能地将每个内容块匹配到最合适的幻灯…

夏相 1月22日 00:09
这里是怎么为每个内容快智能的匹配到最合适的幻灯片样式的？

SaintGeorge 1月22日 09:09
这些内容块 chunk 是大纲负责处理的，调用的是大模型，比如 chunk 1 2 3 的内容让在第一页， chunk4 5 放在第二页。至于这一页用哪个 ppt 模版，则是另一个大模型负责，根据这一页的大纲进行选择，比如这页里文字内容多，那就选个文本框多的 PPt 模版。

飞书用户5060ND 1月27日 17:53

LLM-as-Judge是怎么对生成效果进行评估的?

评估的标准包含三个方面，Prompt的编写大致如下：

- **内容**：评估幻灯片中展示的信息，从三个角度对内容质量进行评估：信息量、文本内容的清晰度和质量、以及视觉内容的辅助作用。高质量的文本内容应当清晰、有冲击力，传达恰当的信息量。同时，图片应当能够补充和强化文本内容，使信息更易于理解并更具吸引力。具体评价标准：
  - 1 分（差）：幻灯片文字存在严重语法错误或结构混乱，难以理解。
  - 2 分（偏下）：幻灯片缺乏明确的重点，文字表述生硬，整体组织松散，难以吸引听众。
  - 3 分（一般）：内容清晰完整，但缺少视觉辅助，使整体吸引力不足。
  - 4 分（良好）：内容清晰、铺陈充分，但图片与主题相关性弱，限制了表达效果。
  - 5 分（优秀）：内容结构完善，重点突出，文字与图片相辅相成，成功传达信息。

- **设计**：从三个方面对设计维度进行评价：配色方案、视觉元素和整体设计。具体来说，幻灯片的配色方案应当有明显的对比度，以突出内容，同时保持整体的和谐。视觉元素（如几何图形）的使用可以让幻灯片设计更具表现力。最后，良好的设计应遵循基本设计原则，比如避免元素重叠，并确保设计不会干扰内容的表达。具体评价标准：
  - 1 分（差）：风格冲突，导致内容难以阅读。
  - 2 分（一般）：仅使用单调的黑白配色，可读性尚可，但缺乏视觉吸引力。
  - 3 分（中等）：采用基础配色方案，但缺少图标、背景、图片、几何形状（如矩形）等辅助视觉元素，看起来较为平淡。
  - 4 分（良好）：配色和谐，并添加了一些视觉元素（如图标、背景、图片、几何形状）；但整体设计仍存在细微瑕疵。
  - 5 分（优秀）：风格和谐且富有吸引力，使用图片、几何形状等辅助元素，显著提升了视觉效果。

- **连贯性**：根据逻辑结构和上下文信息来评估连贯性。当模型能够构建一个引人入胜的故事线，并融入丰富的上下文信息，使观众能够顺畅地跟随内容时，就实现了有效的连贯性。我们通过分析演示文稿中提取的逻辑结构和上下文信息来评估连贯性。具体评价标准：
  - 1 分：逻辑结构混乱，观众难以理解。
  - 2 分：逻辑结构总体合理，但过渡处存在小问题。
  - 3 分：结构清晰、逻辑性强，各部分衔接流畅，但缺少必要的背景信息。
  - 4 分：逻辑流程条理清晰，并包含基本背景信息（如演讲者、日期或机构）。
  - 5 分：叙事结构引人入胜且组织严谨，详尽全面地包含背景信息（演讲者/机构、日期及致谢或结论）。

如何证明你们的评价体系是合理的?

两步验证：

是首先有个大模型根据页数确定每页对应几个内容块，再将内容块转成大纲，然后再有一个大模型根据此大纲进行 PPT 版式的选择是嘛?

S SaintGeorge 1月27日 18:01

对

首先生成大纲，

振柯 李振柯 2025年12月31日

这个大纲是什么格式的？最终生成 PPT 的过程中是：1.每选择好一张幻灯片，填充完这张幻灯片后，再找下一张 2.直接把所有幻灯片都找完，统一填充 想问一下是哪种流程呢

S SaintGeorge 2025年12月31日

第二种，先生成完整的大纲，再基于大纲，生成每一页的 ppt

振柯 李振柯 2025年12月31日

@SaintGeorge 这里的大纲是 markdown 格式还是 ppt 格式呀

S SaintGeorge 2025年12月31日

大纲每一条都是 json 格式的，包含很多 OutlineItem 格式的字段，包含以下字段：

```
{
  "purpose": "introduce ...",
  "section": "Introduction",
  "indexs": {"Section 1": ["Section 1.1", "Section 1.2"]},
  "images": []
 }
```

振柯 李振柯 2025年12月31日

@SaintGeorge 到时候是一条对应一张 ppt 嘛还是多条对应一张

S SaintGeorge 2025年12月31日

一对一的

振柯 李振柯 1月3日 12:09

大纲的每一条信息是不是已经把对应页的内容以及排版都说清楚了，到时候直接调用 API 操作即可

S SaintGeorge 1月3日 12:11

是的

用户上传的PDF文件

Y ycking 2025年11月12日

面试官问，如果是扫描件的

1. 用PPTAgent自动生成了120份PPT（每份都基于一份模板和一份PDF内容，其中PPT模板从Zenodo10K数据集中抽样得到，涵盖了不同领域、风格和排版，同时为每份PPT随机配对了同领域的PDF内容（如讲义、论文或百科条目等））。
2. 每份PPT都让大模型和人工分别打分（在内容、设计、连贯性三维度上），对比这两种评分结果的一致性，验证自动评价体系是否“符合人类感知”。

我们为了验证自动评价体系的合理性，采集了120份由PPTAgent自动生成的PPT，每份PPT都基于一份公开PPT模板和一份同领域PDF内容。每份PPT请3位有经验的老师独立打分，取均值作为人工分，同时用大模型分别打分。最后我们将人工均分与大模型分数组成配对样本，计算了**皮尔逊相关系数**，大于0.7，说明自动评分体系与人类感知高度一致。

还有没有用其他的评估指标？

- **生成PPT成功率**：即能否不报错、顺利生成每一页PPT，且输出结构完整。我们的生成成功率超过了95%，相比于KCTV提升了约10个百分点。这种提升主要归因于以下三个因素：1）本系统专注于内容修改，避免了复杂的样式操作。2）我们精简的API设计使得LLMs能够轻松执行任务。3）API式的编辑增强了LLMs对幻灯片的理解，并提供了自我修正的机会，使它们能够生成准确且稳健的动作。
- **其他指标**：Rouge_L用于**辅助证明我们的PPT内容和原文信息没有丢失或胡编乱造**。Rouge_L平均13.43，与对照方法基本持平，说明PPTAGent生成的PPT中的内容能比较好的遵循原始文本。

Zenodo10K是一个什么样的数据集？

Zenodo10K 是一个由 公开的PPT数据集，收录了超过 10,000 个 PPT。收集了包括文化、教育、科学、社会、科技等多个领域，且PPT长度、风格多样，常用于幻灯片自动生成与设计评估。

怎么和对照方法做比较的呢？

对比了两种方法：

- 基于规则的方法：DocPres，通过多阶段端到端模型生成文字详细的幻灯片，使用基于图像相似性的排名算法向幻灯片添加图像，并通过一种基于相似度的机制引入图片。
- 基于模板的方法：KCTV，先创建一个中间格式的幻灯片，然后利用预定义模板将其转换为最终的演示文稿。

这些基线方法不处理视觉信息，不包含视觉模型。

还是用之前说的120组“PDF输入+PPT模板”，三种方法分别跑一遍，大模型打分，计算平均分，实验结果显示，在内容丰富度、设计美观性、结构连贯性三项指标上，我的方法较模板法/规则法提升13%-29%，结构连贯性提升超25%。

未来有哪些优化/还存在什么问题（必准备）

- **问题1：生成的图片和文字有部分重叠现象**

面试官问，如果是扫描件的PDF，也可以用同样的方法吗

朱时韵 2025年11月12日

不能，本项目的代码用的是marker 这个包，只能处理文本型 pdf，而扫描的 PDF 本质是图像集合，这类文件没有可直接读取的文本数据。github 上最新版本的代码改成用 mineru 来处理 pdf，mineru 是可以处理扫描版 pdf 的，它可以自动检测出其图像属性并启用 OCR 模式，会先通过自研的 DocLayout - YOLO 模型做版面分析，定位文本、表格、公式等元素的位置，再调用集成的 PP - OCRv5 多语言模型将图像中的内容识别为可编辑文本，后面的操作就是一样的了。

转化为markdown格式

sanen 2025年9月16日 （编辑过）

这里怎么转化的呢？MInerU吗？

SaintGeorge 2025年9月17日

用的 marker， 这个项目https://zhuanlan.zhihu.com/p/26166537484

提取PPT中所有的图像

刘志豪 2025年9月2日

这里为什么要提取 PPT 的图片，PPT 不是只作为模板吗，然后不是只要看他每页的结构就行，不是也用占位符替代了图片，为什么这里还要提取图片并且描述嘞

SaintGeorge 2025年9月2日

是的，生成描述对未来的 PPT 生成没有用，这一步可以去了，识别图片只是为了未来替换为纯色块。

每一类PPT

李振柯 1月3日 17:06 （编辑过）

这里的每一类是指的层次聚类分组后的每一组 PPT 嘛，每一组的布局风格是否完全一致呢？

SaintGeorge 1月3日 23:08

对，聚类后，让大模型对每一类进行分析，一般不会完全一致

可以在每次API编辑操作执行之前，检测当前页哪些区域已经有元素了，在prompt里注明这些有元素的位置，要求不要发生重叠。为了确保完全没有重叠，在每次 API 编辑动作执行后，利用新元素的位置和尺寸信息做一次布局校验，如果仍有重叠，则要求llm重新生成。

- **问题2：缺少实时可视化**

目前系统缺少对用户实时可见的预览和干预界面，用户无法在生成中途微调。未来考虑构建前端可视化预览面板，每次API编辑后即时渲染 HTML 版幻灯片，允许用户通过对话对PPT进行即时修改，但这可能会引入多轮对话导致的超长上下文问题，可以通过提示压缩或者上下文分割的方式缓解。

- **问题3：PPT章节之间缺乏过渡**

在插入过渡页时，要求模型首先对上一章进行总结，用“到目前为止，我们已经了解了”类似的口气，并将总结添加到上一章的最后一页PPT之中。对于过渡页之后的本章第一页PPT，要求模型总结本章与上一章之间的联系，用“基于上一章讨论的xx,接下来，我们将探讨……”的口气，并插入到本章第一页PPT的起始。

- **问题4：上传了复杂的PPT模版时，生成效果混乱**

对于“自动编排API编辑命令”这种高结构化、强约束的任务，仅靠prompt往往只能应付简单、模板化的需求。一旦遇到页面结构复杂、多轮编辑、需要判断父子元素或跨页操作时，Prompt-only方式会出现准确率下降、指令漏掉、顺序混乱等问题。

可以构造数据集对7B左右大小的大模型做微调，因为这个任务本质是结构化推理+命令生成，不需要极强的文本理解和常识推理，重点在于“结构对齐”和“序列逻辑”，所以7B大小的模型是可以胜任这个任务的。

数据集如何构造?

如果有真实用户编辑日志或者大量高质量PPT变更数据，就可以用这些pair做指令微调，主要目的是“让LLM学会编辑命令编排”。

输入（X）：

- 结构化PPT页面（HTML/DOM/JSON形式，含页面所有元素的id、类型、内容、父子关系）
- 变更指令（如大纲文本、图片替换、段落增删需求等）
- API文档（描述可以用的API、参数格式、用法说明）

输出（Y）：

- 一组API编辑命令（如 `replace_paragraph(1, 0, "新内容")`、`clone_paragraph(2, 1)` 等），按顺序执行即可把页面变成目标效果。

样本举例：

输入（页面+指令+API文档）	输出（API调用
原内容 , [("title", "text", 0, ["原内容"], ["新内容"])]	replace_paragraph(1, 0, "新内容"
...	...

- **问题5：若用户上传的PPT模板质量较差，会导致生成的PPT质量不佳**

因为目前最终的PPT是在模板PPT的基础上生成的，如果模板PPT就风格单一，结构混乱，那最终的PPT也不会很优质。未来可以构建一个PPT库，收集了一些高质量的PPT模板，为每个PPT模板生成文字性描述，根据用户上传的文本和用户需求，通过RAG检索最合适的模板。

聚类和归纳

sanen 2025年9月25日

面试官问怎么评估聚类效果？实际效果怎么样

SaintGeorge 2025年10月13日

评价指标有很多，比如轮廓系数（0.57）、DBI（0.83），以及这个项目相关的一些指标，比如让大模型评价同一类中 PPT 版式的一致程度（0.7）、计算簇内 PPTembedding 之间的余弦相似度（0.87）等。

vision Transformer

飞书用户9273TT 2025年9月13日

为什么选择这个图片特征提取模型，除了这个还有哪些其他的图片特征提取模型

SaintGeorge 2025年10月13日

类似的模型很多，比如 google/vit-base-patch16-384-in21k、mae-vit-base 等，为什么用 xx 模型之类的问题参考：

vision Transformer的base版本（google…

rhy 2025年12月11日

面试官问这里 VIT 模型做 embedding 时的图片的原始维度是多少？输入维度是多少，输出维度又是多少？

SaintGeorge 2025年12月11日

原始维度 3x224x224，输入维度 197x768，输出 1x768，详见 多模态体系知识搭建 和https://arxiv.org/pdf/2010.11929

陈坤 3月5日 22:08

原始图像分辨率 224x224 会不会太小了，图片细节丢失太多效果不好？

SaintGeorge 3月5日 22:11

这个模型的原生分辨率就是 224x224，这里可以换为更新的 vlm 模型

层次聚类

飞书用户9273TT 2025年9月13日

目前最好的ppt生成产品有哪些，做过调研吗？

是的，我做过一些系统性的调研。整体来看，AI PPT 工具大致分为两类：

- 一类是生成类模型 + 模板驱动，例如 Kimi PPT 或白果 AI。这类产品通常基于大语言模型生成大纲，再结合预设的版式模板和图像生成，优点是速度快、排版美观，但在交互层面灵活性有限。
- 另一类是 Agent 化的方案，代表是 Minimax Agent。它不仅能生成 PPT，还可以通过多轮自然语言交互调整内容，并具备工具调用能力（例如检索资料、生成图像、插入外部资源），从工程角度看，它更像是一个多工具编排的工作流系统，而不只是“单步生成”。

在体验层面，我发现 Minimax 的交互和扩展性最强（也是价格最高），本质上得益于它的 Agent 架构；而 Kimi 和白果 AI 则通过优化 prompt + 模板匹配，达到了非常快的落地效果，适合偏“高效出稿”的场景。

其他工具像 Gamma、Slidesgo、Autoppt、Presentia AI 以及 Microsoft Copilot，其核心差异更多在于生态集成度（比如 Copilot 依赖于 Microsoft Office 生态）。

总体来说，如果关注技术可扩展性和复杂任务处理，Minimax 的架构更有代表性；如果关注生成质量和速度，Kimi 或白果 AI 的产品化程度更好。

全文评论

刘志豪 2025年9月2日

面试官提问：目前最好的 ppt 生成产品有哪些，做过调研吗？

朱时韵 2025年9月2日 （编辑过）

@刘志豪 是的，我做过一些系统性的调研。整体来看，AI PPT 工具大致分为两类：

一类是生成类模型 + 模板驱动，例如 Kimi PPT 或白果 AI。这类产品通常基于大语言模型生成大纲，再结合预设的版式模板和图像生成，优点是速度快、排版美观，但在交互层面灵活性有限。

另一类是 Agent 化的方案，代表是 Minimax Agent。它不仅能生成 PPT，还可以通过多轮自然语言交互调整内容，并具备工具调用能力（例如检索资料、生成图像、插入外部资源），从工程角度看，它更像是一个多工具编排的工作流系统，而不只是“单步生成”。

在体验层面，我发现 Minimax 的交互和扩展性最强（也是价格最高），本质上得益于它的 Agent 架构；而 Kimi 和白果 AI 则通过优化 prompt + 模板匹配，达到了非常快的落地效果，适合偏“高效出稿”的场景。

其他工具像 Gamma、Slidesgo、Autoppt、Presentia AI 以及 Microsoft Copilot，其核心差异更多在于生态集成度（比如 Copilot 依赖于 Microsoft Office 生态）。

总体来说，如果关注技术可扩展性和复杂任务处理，Minimax 的架构更有代表性；如果关注生成质量和速度，Kimi 或白果 AI 的产品化程度更好。

为什么选择层次聚类，为什么不用 K-means 聚类

SaintGeorge 2025年9月13日

层次聚类不需要事先设定簇数，层次聚类是自底向上（或自顶向下）的逐步合并（或拆分），只需设定一个相似度阈值 θ，当小于阈值时停止合并即可，而 K-means 必须事先指定簇数 k。在 PPT 场景下，不同模板、不同数据集的版式种类差异很大，事先很难确定最佳簇数。而 k-means 西药预先设置 k 值，而且对初始值非常敏感，不同的初始质心可能得到完全不同的结果，整体效果不如层次聚类

每次贪心地选相似度最高的一对未合并的…

飞书用户5060ND 1月14日 16:07

这个过程只是幻灯片两两合并，看代码中还包含一张幻灯片合并到某个簇的计算过程，即计算与簇中所有幻灯片相似度再取平均值？

SaintGeorge 1月14日 16:37

对的，要计算新幻灯片跟哪个簇更接近，然后合并进去

我们会在每个类别的聚类结果中，选取包…

用户095466 2025年12月29日

目前的 ppt 是已经转化成了图片了，那元素数量是模型根据图片算出来的吗

SaintGeorge 2025年12月29日

对，模型会分析图片中有多少元素（比如文本框，图片等）

切分chunk

sp 3月22日 17:45 （编辑过）

最后得到的 chunk 是按照最小层级的标题行来切分的吗？比如 1.1 和 1.2 分别是两个 chunk，而不是 1（包含 1.1 和 1.2）和 2（包含 2.1 和 2.2）是两个 chunk。因为正则是抽取所有标题行，但是代码里的 prompt 又是只提取顶级标题行

SaintGeorge 3月22日 17:46

对，按照最小层级来划分，但是如果两个 chunk 加起来都小于一个阈值的话，可以讲他俩合并

用户950255 2025年10月13日

面试官提问：这个项目里一共用了哪些模型，参数量分别是多少，分别在哪个具体的环节用的，如何选择的这些模型？

SaintGeorge 2025年10月13日 （编辑过）

用了 gpt4o 作为视觉模型和语言模型，GPT 是闭源模型不知道其细节，你也可以替换为你熟悉的模型。

视觉模型用于对 PPT 和 PDF 中的图片进行理解与描述，用于生成图像标题等。语言模型用于标题结构调整、段落摘要、元数据合并、内容长度校验与重写、表格标题生成等。

为什么选择模型参考这个回答，

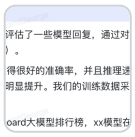

用户950255 2025年10月15日

在这段描述“系统在 Zenodo10K 等多领域公开数据集上测试，内容、设计、连贯性三项指标较模板法/规则法基线平均提升 13%~29%，结构连贯 性得分提升超 25%，最终平均得分 3.67/5。”中，

模板法/规则法基线指的是其他的 ai 类似产品比如 kimi，白石这种基于规则模板生成的 ppt 的 LLM-as-Judge 给出的打分吗？

最终平均得分 3.67/5 中的 5 是满分吗，这是哪个分数，是 LLM-as-Judge 给出的打分吗？

朱时韵 2025年10月15日

@用户 950255 5 分是满分，这个规则是自己设定的，看问题“LLM-as-Judge 是怎么对生成效果进行评估的？”的回答。

模板法/规则法基线不是指的是其他的 ai 类似产品，kimi、白石也不是基于规则模板生成的 ppt，他们具体是怎么做的目前还不知道，因为都是闭源产品，这里的模板法指的是 KCTV（https://aclanthology.org/2024.findings-emnlp.906/），规则法指的是 DocPres（https://arxiv.org/abs/2406.06556），原论文中也是这么做的

喻梦婷 2025年12月31日

这个项目会涉及哪些八股呀？

SaintGeorge 2025年12月31日

@喻梦婷 主要是 agent 相关的八股

李振柯 1月4日 18:36

@SaintGeorge 视觉模型不是 ViT 嘛，简历那边说使用 VIT 模型提取幻灯片页面的图像 embedding

SaintGeorge 1月4日 18:53

是 vit，google 哪个模型就是 vit

sp 3月22日 18:33

谷哥居姐，这个项目是不是就是把一些比较复杂的操作，比如总结、提取结构内容模式等，用 prompt 交给大模型来做了呀？涉及到的大模型方面的技术架构，是不是只有 prompt 工程、function calling 和 llm-as-judge？它能称之为 agent 吗？如果面试官觉得这个项目只是用大模型来代替实现了一些功能，我该如何回答呢？还是说 agent 本身就是这样的？

SaintGeorge 3月22日 18:46 （编辑过）

这个项目有一个加强版，加了强化学习进去。原始版本就像你说的这样，主要是调用大模型。这个可以说是 agent，因为 agent 本质就是调用大模型按照指定的流程完成用户的意图，这个 agent 比较简单，没有涉及记忆，工具调用，skills 等东西

通过Prompt指令（如“整理重复标题、…

李享聪 3月8日 17:11

居姐谷哥，有个疑问，在切分 chunk 的过程中并不会生成 JSON 吧，只是大模型会基于语义和编号筛选出几个顶层标题？

SaintGeorge 3月8日 18:45

这个 json 你可以理解为输出的内容，大模型筛选出标题后，以 json 的格式输出出来。

生成指定页数的大纲

谢秀梅 2025年6月21日

这里的大纲是什么格式长什么样的呀，有没有例子说明怎么根据大纲和文本内容选择调用哪个 API 工具进行填充(就是如何定位到要改变的区域和元素)。想通过具体例子理解一下这个流程，谢谢！

SaintGeorge 2025年6月21日

generate_outline 生成大纲，大纲的例子就是：OutlineItem(purpose="Introduce Tom's appearance and color variations.", section='汤姆的角色描述', indexs={'汤姆的角色描述': ['外貌与颜色变化']}, images=[])

_select_layout 函数根据大纲选择布局和并生成文本内容；然后 self.staffs["editor"]生成要写在幻灯片内容中的新元素；然后 _generate_commands 根据新旧元素之间的差异生成命令，例如：("title", "text", "quantity_change: 0", ["算法详解"], ["汤姆的角色描述"])；最后 self.staffs["coder"]根据命令从 5 个 api 中选择一个进行执行。

更具体的内容可以自己跑一下代码，根据代码讲解哪个文档，输出一下过程中关键的元素。

展开

谢秀梅 2025年6月21日

@SaintGeorge 好的，谢谢！

最后模型生成的PPT页数是多少页

刘志豪 2025年9月3日

面试官问：你生成一个多页的 PPT 的话会有一个很长的

user132269 3月26日 21:25

@SaintGeorge 那会不会有点跟不上时代了，还能写上简历嘛?

SaintGeorge 3月26日 21:26

这个基础版本是用来投开发的，加了强化的是用来投算法的

user132269 3月26日 21:27

@SaintGeorge 我的目标就是 Agent 开发，目前是准备了星球的股票 agent 和 pptAgent1.0 版本，请问这样够吗？项目该如何准备呢，直接背文档吗

SaintGeorge 3月26日 21:29

先把文档里大部分问题弄明白，然后可以用大模型模拟面试面试，感觉准备的差不多了就去面，随着面试再不断改善自己的话术，弄明白自己不了解的问题。

user132269 3月26日 21:30

@SaintGeorge 收到，感谢你

HTML，这么长的上下文是如何进行管理的?

SaintGeorge 2025年9月3日

1. 这个项目里采用了滑动窗口的思想，也就是只会把当前章节的 ppt 加入到这一页 ppt 生成的上下文中，如果没有章节或者当前章节超过了 5 页 ppt，那就只把最近 5 页加入上下文。

另外针对超长上下文（常见于多轮对话场景），常用的还有以下方法：

1. 维持一个上下文窗口（比如 10），10 轮前的对话用大模型进行总结后加入上下文，10 轮内的保留完整对话。

2. 将历史对话存入向量数据库，对话前先检索相关片段加入上下文。

3. 上下文拆分成多段，分段交给大模型进行处理，最后再汇总结果。

展开

最后模型生成的PPT页数是多少页

sp 3月22日 18:05

这个项目涉及记忆吗？如果用户上传的 pdf 很长，大模型是否需要一次性全部加载，然后生成相应的大纲和后续的编辑操作等

SaintGeorge 3月22日 18:07

这个项目不涉及记忆，上传的东西很长的话可以分块加载进来，每一块进行 summary，最终把文档压缩到上下文区间内

sp 3月22日 18:07

了解，谢谢谷哥

编辑过程是“多轮迭代式”的

谢秀梅 2025年6月21日 （编辑过）

第一次生成了完整的 PPT 进行二次编辑的时候支持用户输入关于修改内容的文本描述然后让大模型选择对应的 API 进行编辑吗？还是说二次编辑的时候是通过修改第一次生成的大纲

SaintGeorge 2025年6月21日

@谢秀梅 目前多轮迭代的实现是如果生成的 api 不能正常运行，会将报错信息返回给生成 api 的 llm，要求根据指令重新生成 api，不修改大纲。

你说的第一点是未来优化中做

你说的第一点是未来优化中做的，也就是每执行完一个 api，就渲染出最新的 ppt 页面，让用户可以输入修改内容，从而让 llm 可以重新编辑。

大模型是如何决定现在要用哪个API工具…

张笑 2025年12月10日

生成大纲和生成 API 命令是用什么模型呀?

SaintGeorge 2025年12月10日

默认用的 deepseek-chat，这个可以换成你熟悉的

张笑 2025年12月10日

用多大的模型比较合适呀?

SaintGeorge 2025年12月10日

调 API 的话就用 DeepSeek，gpt，doubao 等模型，这些都挺大的，几百 B。如果你想用本地部署的模型，大家部署的模型一般是 7 或者 30b 左右的规模

张笑 2025年12月10日

谢谢!

将变更需求与当前页面结构（如HTML、…

谢秀梅 2025年6月21日

这里的对齐具体是怎么实现的

SaintGeorge 2025年6月21日

主要验证元素和图片是否存在，文本是否超长

成功率

sanen 2025年10月11日

想问一下在什么情况下会失败?如果要求 ppt 生成的页数比较多它能成功生成吗?很想跑通代码，但是原项目代码更新了，没能跑通呜呜呜

SaintGeorge 2025年10月11日

失败主要是因为模型 API 有问题。你用网盘里上传的代码吧，应该能跑通，原项目确实一堆 bug

sanen 2025年10月11日

好嘟，我试试，谢谢谷哥!

LLM-as-Judge 使用 GPT-4o 作为评判模…

SaintGeorge 1月6日 21:06

两个思路，1 是说 gpt4o 当时刚出，然后说 gpt4o 的优点，比如在某某 benchMark 上指标达到多少，但 gpt 是闭源模型，没法说他的技术细节。2 是说对比了 gpt4o 和 qwen2.5vl 等模型的效果，人工评测感觉 gpt4o 的评价更准确。

用户766854 1月6日 21:07

好的，谢谢谷哥

2 分（一般）：仅使用单调的黑白配色，…

振柯 李振柯 1月4日 16:28

设计的打分是不是挺依赖用户上传的 ppt 模板呀，我看这里涉及到了 ppt 的背景什么的。同一份 pdf，两份不同的 ppt 模板（一份单调，一份丰富），那丰富的那份肯定要比单调的得分高呀。

S SaintGeorge 1月4日 16:31

是的，对比我们的方法和其他模型的时候，会使用相同的 pdf 和 ppt 模板，保证公平对比。

评价体系是

飞书用户6802ZM 1月13日 16:51

eval 部分在代码里有体现么？面试官问人工评分是自己做的么，具体怎么做应该怎么·回答

S SaintGeorge 1月13日 17:09 （编…

有，ppteval.py。人工评可以说是标注同学（或者其他人）做的，这个也没啥含金量。

生成的图片和文字有部分重叠现象

S sanen 2025年10月10日

请问为什么会发生重叠现象呢？不是直接对原有布局进行修改吗？图片应该只会放在 image 区域，文本放在 text 区域，这样子的话为什么还会重叠啊？

S SaintGeorge 2025年10月10日

比如原始的 text 区域面积是 10，我想往这一块发的文字很多，需要 20 的面积，这就可能会跟旁边的图像区域重叠。

S sanen 2025年10月10日

明白了，谢谢！

> 未来可以构建一个PPT库，收集了一些高…

顾文荟 3月30日 21:59

所以现在的层次聚类只是根据用户上传的那一份 PPT 进行的吗，并没有一个根据很多 PPT 生成的模板库？

SaintGeorge 3月30日 22:15

对，这个项目是只对用户传递 ppt 进行聚类。因为用户传了 ppt，就意味着他想让我们参考他的 ppt 风格。如果用户不传 ppt，那就可以用你说的这种，从 ppt 模板库里聚类出几个模板

顾文荟 3月30日 22:15

明白了，谢谢！

> 这类产品通常基于大语言模型生成大纲，…

sanen 2025年9月16日

本项目和这些产品有什么区别吗

朱时韵 2025年9月16日

他们是闭源的，不知道他们咋实现的，效果上也没有比本项目好太多，现在 AI 做 PPT 基本处于不可用的状态，不过也可以认为是有发展潜力的状态

sanen 2025年9月16日

好的，谢谢